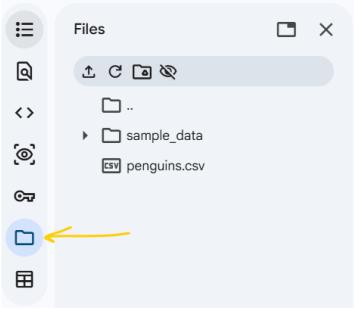
Pandas - Analiza danych

Komputerowe wspomaganie decyzji

1 Analiza danych

Do analizy i manipulacji danych będziemy korzystali z biblioteki Pandas (Python Data Analysis). Bazuje ona na NumPy (co daje szybkie obliczenia), ale jest przystosowana do danych tabelarycznych. Razem z instrukcją jest załączony plik **csv** (ang. *comma separated values*) zawierający dane na temat pingwinów z Archipelagu Palmera. Na Google Colab możemy ten plik przesłać na dysk po uruchomieniu środowiska (panel po lewej stronie):



Będzie on następnie dostępny do odczytu:

```
import pandas as pd
penguins = pd.read_csv('penguins.csv')
```

Pamiętajmy jednak, że po opuszczeniu strony pliki zostają wyczyszczone. Zobaczmy teraz, jak wyglądają nasze dane, wyświetlając kilka pierwszych rekordów:

```
penguins.head()
```

Dane są przechowywane jako w obiekcie DataFrame jako nazwane kolumny, o określonym Dtype:

```
penguins.info()
```

Możemy też zauważyć, że nie wszystkie rekordy są kompletne. Ilość brakujących możemy w prosty sposób wyświetlić:

```
penguins.isna().sum()
```

Zamiast uzupełniać brakujące rekordy, możemy je usunąć:

```
penguins = penguins.dropna()
```

- Ile procent stanowiły usunięte rekordy? Sprawdź wielkość nowej tablicy za pomocą jednego z wcześniejszych poleceń, albo za pomocą `.shape`
- Dobrze jest także sprawdzić, czy wszystkie rekordy są unikalne - odpowiednikiem `.isna()` dla brakujących rekordów jest tutaj `.duplicated()`

1.1 Date kategoryczne

Dane kategoryczne (nazywane też danych jakościowymi lub zmiennymi kategorycznymi) to dane, które dzielą obiekty lub obserwacje na skończone grupy lub kategorie. Takie dane zawierają właśnie kolumny `"species"` oraz `"island"`, `"sex"`.

Wybierzmy jedną z kolumn. Zamiast jak w NumPy odnosić się do kolumn po indeksach, mamy możliwość skorzystania z nazw kolumn do wyboru danej kolumny:

```
penguins["species"]
```

Podstawowym pytaniem jest teraz, jakie gatunki pingwinów są reprezentowane w naszym zbiorze? Oraz z ilu wysp one pochodzą? Dla kolumn `"species"` oraz `"island"`:

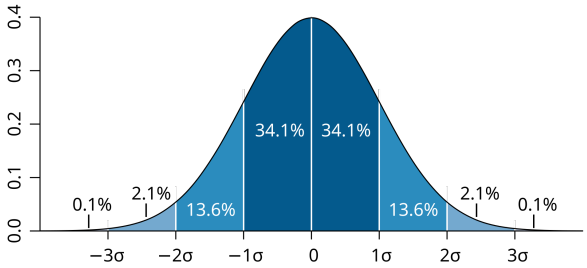
- Wypisz unikalne wartości za pomocą metody `.unique()`
- Wypisz ile pingwinów danego rodzaju jest w naszych danych za pomocą `.value_counts()`, podobnie dla wysp.
- Mamy także możliwość tworzenia wykresów dla danych Pandas: dla wyników poprzedniej metody zastosuj `.plot(kind="bar")` w celu graficznego przedstawienia wartości. Może tutaj być konieczne zaimportowanie matplotlib oraz wykonanie `plt.show()` w celu pokazania wykresu.
- Utwórz tabelę krzyżową: `pd.crosstab(island, species)`
  pokazującą ile pingwinów danego rodzaju jest na danej wyspie, zapisz wynik do arkuszu excel, oraz przedstaw to zestawienie na wykresie.

1.2 Dane numeryczne

Pozostałe cztery kolumny zawierają dane numeryczne na temat dziobów, płetw oraz masy ciała pingwinów. Szybkie zestawienie tych wartości możemy otrzymać za pomocą:

```
penguins.describe()
```

Otrzymany informacje o średniej (**mean**), odchyleniu standardowym (**std**) oraz kwantylach. większość algorytmów, testów oraz rozważań zakłada rozkład normalny w danych:



Wiele zjawisk naturalnych i społecznych wykazuje tendencję do takiego rozkładu, a średnia i odchylenie standardowe pozwalają go stosunkowo łatwo opisać. Dodatkowo, dzięki centralnemu twierdzeniu granicznemu, rozkład normalny pojawia się jako przybliżenie rozkładu sum i średnich wielu niezależnych zmiennych. Założenie to upraszcza obliczenia i umożliwia stosowanie wielu sprawdzonych metod statystycznych, choć nie zawsze jest spełnione w rzeczywistych danych.

Wybierzmy jeden z gatunków pingwinów z naszych danych:

```
adelie = penguins[penguins["species"] == "Adelie"]
```

Sprawdźmy teraz jak wygląda rozkład "bill_length_mm" dla tego gatunku:

```
import matplotlib.pyplot as plt
import seaborn as sns
sns.histplot(
    data=adelie["bill_length_mm"],
    kde=True, stat="count"        # kernel density estimation
)
plt.show()
```

Sam wykres nie zawsze może być jednoznaczny, wobec tego **oblicz dla niego pewne wartości statystyczne**:

- Czy średnia (`.mean()`) leży blisko mediany (`.median()`)?
- Jak wygląda skośność oraz kurtoza dla naszego rozkładu:

  ```
  from scipy import stats

  print("Skewness:", stats.skew(x))
  print("Excess kurtosis:", stats.kurtosis(x))
  ```

  Dla rozkładu normalnego wartości te powinny być w przybliżeniu zerowe. Inna wartość skośności mówi nam o tym, że wykres nie jest symetryczny. Natomiast różniąca się od zera wartość kurtozy mówi nam o wartościach skrajnych (ogonach) - może ich być albo więcej albo mniej niż dla rozkładu normalnego.
- Kwantyle naszego rozkładu możemy porównać do kwantyli rozkładu normalnego za pomocą tzw. wykresu kwantyl-kwantyl (Q-Q plot): `stats.probplot(x, dist="norm", plot=plt)` - punkty powinny leżeć w przybliżeniu na prostej.

Podobnie sprawdź czy rozkład długości dziobów dla "Chinstrap" jest normalny. Jeżeli przypuszczamy, że rozkład nie jest normalny możemy zastosować test Shapiro-Wilka:

```
statistic, p_value = stats.shapiro(x)

print("W statistic:", statistic)
print("p-value:", p_value)
```

Interesuje nas tutaj wartość `p_value`:

- $p \geqslant 0.05$ - test nie przeczy normalności (ale jej nie udowadnia)
- $p < 0.05$ - test wykrył brak normalności

Testujemy tutaj pewną hipotezę zerową - dane zostały zaczerpnięte ze zbioru normalnego. Dla dostatecznie małych wartości p możemy ją odrzucić. Oczywiście jeżeli testowi nie udało się odrzucić hipotezy, nie dowodzi to normalności. Możemy zastosować po prostu inny test, np. Anderson-Darling:

```
result = stats.anderson(x, dist="norm")

for i in reversed(range(5)):
  if result.statistic > result.critical_values[i]:
    print("Normality rejected at",
          result.significance_level[i],
          "% significance level.")
    break
```

Gdzie odrzucamy hipotezę o normalności z pewnym poziomem istotności. Przykładowo, dla poziomu istotności 5%, około 5% tych testów niepoprawnie odrzucałoby normalność zbioru normalnego. Typowo jest to akceptowalny poziom, który wcześniej był domyślnie zastosowany przy teście Shapiro-Wilka.

1.3 Porównanie dystrybucji

Wcześniejszy rozkład długości dziobów dla pingwinów `"Chinstrap"` wyglądał dosyć podejrzanie. Jego dwa wierzchołki mogą wynikać z tego, że są to tak naprawdę dwa różne rozkłady nałożone na siebie.

- Podziel pingwiny `"Chinstrap"` na samce i samice. Które z nich mają większe dzioby? Porównaj tutaj średnie i mediany.
- Narysuj dwa histogramy długości dziobów dla samców oraz samic na jednym wykresie wywołując dwukrotnie `sns.histplot(..., label="Female")` oraz dodając `plt.legend()` przed `plt.show()`. Oczywiście odpowiednio dobierz parametr `label` zależnie od histogramu.
- Wykonaj podobny wykres dla pingwinów `"Adelie"`. Co teraz sądzisz o normalności tej dystrybucji?

Jeżeli nie jesteśmy pewni czy dwa rozkłady posiadają różne wartości oczekiwane, istnieje oczywiście na to test statystyczny (T-test):

```
result = ttest_ind(
    samples_A,
    samples_B,
    equal_var=False
)

print("t-statistic:", result.statistic)
print("p-value:", result.pvalue)
```

Interesuje nas tutaj ponownie wartość p. Jeżeli jest ona mniejsza od 0.05, to możemy odrzucić hipotezę, że dwie dystrybucje (z których pochodzą nasze obserwacje) posiadają jednakowe wartości oczekiwane.

- Porównaj średnią oraz medianę masy ciała dla pingwinów "Adelie" oraz "Chinstrap". Które pingwiny są cięższe?
- Zastosuj t-test. Czy wartości oczekiwane mas dla tych gatunków pingwinów są naprawdę różne?

